

多语言内容审核模型

技术报告与全面对比分析

基于 microsoft/mdeberta-v3-base
8 个国家 × 4 种训练方法 × 32+ 个模型

2026 年 6 月 12 日

目录

1 项目概述	2
1.1 覆盖国家与语言	2
1.2 任务类型	2
1.3 二分类数据来源	2
1.4 多分类标签定义	3
1.4.1 通用标签 (所有国家)	3
1.5 各国特有标签	3
1.5.1 ID (印尼)	3
1.5.2 SG (新加坡)	3
1.5.3 TH (泰国)	3
1.5.4 ZA (南非)	3
1.5.5 SA (沙特)	3
1.5.6 MX (墨西哥)	3
1.5.7 BR (巴西)	3
1.5.8 TR (土耳其)	3
1.6 各国家多分类标签分布	3
1.6.1 印尼 (ID) —45,753 条, 9 个标签	4
1.6.2 新加坡 (SG) —25,543 条, 9 个标签	4
1.6.3 泰国 (TH) —17,751 条, 8 个标签	4
1.6.4 南非 (ZA) —24,259 条, 9 个标签	4
1.6.5 沙特 (SA) —20,647 条, 9 个标签	4
1.7 基座模型	4

1.8	四种训练方法	4
1.9	多分类训练方法	5
1.10	蒸馏方法 (已弃用)	6
2	二分类模型全面对比	6
2.1	整体对比	6
2.2	违规召回率排名	7
2.3	四种方法平均值对比	7
3	多分类模型全面对比	7
3.1	整体排名	7
3.2	各标签 F1 热力图	8
3.3	印尼 (ID) —最优模型详细结果	8
3.4	泰国 (TH) —详细结果	8
3.5	新加坡 (SG) —详细结果	8
4	模型演进: 印尼 ID v1 → v6	8
5	综合仪表盘	9
5.1	关键发现	9
6	模型部署	10
6.1	HuggingFace Hub	10
6.2	使用方法	10
6.2.1	二分类 Full FT	10
6.2.2	二分类 LoRA (PEFT)	11
6.2.3	多分类 LoRA	11
7	未来工作	11

1 项目概述

本项目旨在构建覆盖 8 个目标国家/地区主流语言的 AI 内容审核模型系统。所有模型基于微软 mDeBERTa-v3-base 预训练模型进行微调，能够检测和分类社交媒体上的违规内容。

1.1 覆盖国家与语言

表 1: 目标国家与语言

代码	国家	语言	数据来源
SA	沙特阿拉伯	阿拉伯语	Reddit, Twitter
BR	巴西	葡萄牙语	Reddit
MX	墨西哥	西班牙语	Reddit
ID	印尼	印尼语	Reddit, Kompasiana
SG	新加坡	英语/Singlish	HardwareZone, Reddit
TH	泰国	泰语	Pantip, Reddit
TR	土耳其	土耳其语	Reddit
ZA	南非	英语/阿非利卡语等	Reddit

1.2 任务类型

1. 二分类 (Binary): 安全内容 vs 违规内容识别, 8 国全覆盖
2. 多分类 (Multi-Class): 9 类违规内容细分, 包括国家特有违规类别(如新加坡的 SG_Racial_Religious_Harassment、泰国的 TH_Lese_Majeste、南非的 ZA_Severe_Racism 等)

1.3 二分类数据来源

二分类训练数据来自两个来源:

- **Datasets_Nine_country**: 各国论坛/Reddit 爬取的原始数据, 每条带有 binary label (0=safe, 1=violation)
- **data_v2**: 细粒度多类标注数据, 用于 Adapter 和 Multi-LoRA 训练

表 2: 二分类数据—两个来源合并

国家	Nine_country	data_v2	合计
SG	89,931	12,815	102,746
TR	90,173	12,132	102,305
ZA	83,606	14,510	98,116
BR	78,867	13,168	92,035
SA	70,100	15,724	85,824
MX	50,787	13,226	64,013
ID	27,222	13,453	40,675
TH	9,515	11,253	20,768

注: Full FT 和 LoRA 使用 Nine_country 数据; Adapter 和 Multi-LoRA 使用 data_v2 数据。

表 3: 通用违规标签定义

标签	中文	定义
Dangerous _{Content}	危险内容	恐怖主义、武器、自残/自杀方法、严重暴力、毒品交易、诈骗、性犯罪、CSAM、血腥内容
Harassment	骚扰	针对个人的侮辱、粗口、网络霸凌、人肉搜索、外貌羞辱
Hate _{speech}	仇恨言论	基于身份的攻击: 种族、宗教、性别、国籍、移民身份
Sexually _{ExplicitInformation}	色情信息	色情内容、性行为描述、约炮、性暗示
Politically _{sensitiveTopics}	政治敏感	非本国政治内容: 外国选举、国际冲突、外国领导人
Cybersecurity _{Malware}	网络安全	恶意软件、黑客攻击、钓鱼、DDoS、凭证盗窃
safe	安全	正常内容, 无违规

1.4 多分类标签定义

1.4.1 通用标签 (所有国家)

1.5 各国特有标签

1.5.1 ID (印尼)

1.5.2 SG (新加坡)

1.5.3 TH (泰国)

1.5.4 ZA (南非)

1.5.5 SA (沙特)

1.5.6 MX (墨西哥)

1.5.7 BR (巴西)

1.5.8 TR (土耳其)

1.6 各国家多分类标签分布

表 4: ID (印尼) 特有违规标签

标签	中文	定义
ID_SARA	印尼宗教种族	针对印尼族群 (Suku)、宗教 (Agama)、种族 (Ras)、群体间 (Antargolongan) 的攻击。包括反华人 (anti-Cina)、反爪哇人、反巴布亚人、政治身份攻击 (ce-bong/kampret/kadrun)
ID_Blasphemy	印尼亵渎/诽谤	宗教亵渎 (Pasal 156a KUHP) 和电子诽谤 (UU ITE)。包括嘲讽安拉/先知/古兰经、对信徒的蔑视、社交媒体上的严重人格攻击

表 5: SG (新加坡) 特有违规标签

标签	中文	定义
SG_Racial_Religious_Harmony	种族宗教和谐	新加坡煽动法令和 MRHA 下的种族/宗教不和谐。CMIO 种族攻击 (华人/马来人/印度人/欧亚裔)。反移民种族言论 (FT/Bangla/Pinoy/PRC)
SG_Vulgarity_Singlish	粗俗 Singlish	极端粗俗的 Singlish 侮辱。重度福建话粗口 (chee bai, kan ni na, lan jiao)。注意: 日常 Singlish 语气词 (lah, lor, leh) 不算违规

1.6.1 印尼 (ID) —45,753 条, 9 个标签

1.6.2 新加坡 (SG) —25,543 条, 9 个标签

1.6.3 泰国 (TH) —17,751 条, 8 个标签

1.6.4 南非 (ZA) —24,259 条, 9 个标签

1.6.5 沙特 (SA) —20,647 条, 9 个标签

1.7 基座模型

所有模型使用 `microsoft/mdeberta-v3-base`, 参数量 279M, 支持 100+ 语言的多语言 DeBERTa 变体。

1.8 四种训练方法

1. **全量微调 (Full FT)**: 所有参数参与训练, 精度最高, 但每国需要 1.1GB 独立模型存储。

```
learning_rate = 1e-5, epochs = 5 (early stopping)
batch_size = 4, grad_accum = 4
optimizer = AdamW + class-weighted CrossEntropyLoss
```

2. **LoRA 微调 (PEFT)**: 低秩适配, 仅训练 0.21% 参数 (600K), 适配器大小 ~3MB。

表 6: TH (泰国) 特有违规标签

标签	中文	定义
TH_Lese_Majeste	冒犯君主	刑法第 112 条。对王室成员的侮辱、嘲讽、威胁。泰国最严重的网络言论罪行
TH_Political_Instigation	政治煽动	泰国国内政治煽动: 推翻政府、军事政变呼吁、选举舞弊指控、暴力抗议号召

表 7: ZA (南非) 特有违规标签

标签	中文	定义
ZA_Severe_Racism	严重种族主义	K-word (kaffir)——南非最严重的种族侮辱词。种族隔离侮辱词 (hotnot, coolie)。种族隔离怀旧/赞美。PEPUDA 法案
ZA_Xenophobia	排外主义	针对南非境内非洲外国人的排外攻击。makwerekwere(贬损词)。Operation Dudula 言论。排外暴力赞美

```
LoraConfig(r=16, alpha=32, dropout=0.1,
            target_modules=["query_proj", "value_proj"])
learning_rate = 5e-5, epochs = 5
```

3. **Multi-LoRA 共享**: 一个基座 (1.1GB) + 8 国 LoRA 适配器 (2MB/国), 通过 `PeftModel.from_pretrained` 热切换国家。

```
LoraConfig(r=8, alpha=16, dropout=0.1)
learning_rate = 2e-4, epochs = 5
```

4. **Adapter 瓶颈适配器**: 在 Transformer 层间插入 bottleneck adapter, 训练 0.5% 参数, 适配器 ~2.5MB。精度最低但训练最快。

```
learning_rate = 1e-4, epochs = 3
batch_size = 32
```

1.9 多分类训练方法

多分类模型统一使用以下配方, 经过 ID 模型 6 个版本迭代验证:

```
LoRA: r=16, alpha=32, dropout=0.1, target=["query_proj", "value_proj"]
Loss: CrossEntropyLoss(label_smoothing=0.05)
Optimizer: AdamW, lr=2e-4, warmup=100 steps
Epochs: 3, Train batch=16, Eval batch=64, max_length=256
Post-processing: per-class grid search threshold + Nelder-Mead joint optimization
Hardware: AMD RX 9070 XT (17GB VRAM) + ROCm 7.2
Training speed: ~1.3 it/s (LoRA on AMD ROCm)
```

表 8: SA (沙特) 特有违规标签

标签	中文	定义
SA_LGBTQ_Content	LGBTQ 内容	沙特禁止的 LGBTQ 相关内容
SA_Religious_Violation	宗教违规	亵渎神明、叛教、宗教侮辱
SA_State_Security_Royalty	国家安全/王室	反政府、反王室家族言论

表 9: MX (墨西哥) 特有违规标签

标签	中文	定义
MX_Narco_Culture	毒品文化	赞美卡特尔 (cartel)、毒枭 (Chapo/Mencho)、毒品民谣 (narco-corridos)、毒品生活方式美化
MX_Gender_Violence	性别暴力	杀害女性 (femicide) 赞美、受害者归咎、大男子主义 (machista) 暴力威胁

1.10 蒸馏方法 (已弃用)

在 ID v2 中尝试了 Label Smoothing Distillation (LSD), 使用 Full FT teacher 模型指导 LoRA student 训练:

$T = 3.0$, $\alpha = 0.4$, $\text{label_smoothing} = 0.05$

$\text{loss} = \alpha * \text{CE}(\text{ls}) + (1 - \alpha) * \text{KL}(\text{teacher}/T, \text{student}/T) * T^2$

结论: LSD 提升有限 (+0.005 以内), 训练速度慢 5 倍 (1.3 vs 7.4 it/s), 不推荐使用。

2 二分类模型全面对比

2.1 整体对比




图 1: 8 国 × 4 种方法的二分类 Macro F1 对比

表 10: BR (巴西) 特有违规标签

标签	中文	定义
BR_Structural_Racism	结构性种族主义	严重反黑人/棕色人种/原住民种族主义。macaco(猴子)。奴隶制历史言论 (senzala)
BR_Political_Extremism	政治极端主义	反民主极端主义: intervencao militar(军事干预)、选举否认、独裁赞美 (1964-1985)

表 11: TR (土耳其) 特有违规标签

标签	中文	定义
TR_Political_Extremism	政治极端主义	反政府极端言论、政变号召、恐怖组织赞美 (PKK 等)
TR_Religious_Extremism	宗教极端主义	宗教极端言论、教派攻击

2.2 违规召回率排名

注: *Multi-LoRA* 的违规召回率普遍最高, 但这是以牺牲 *Clean Recall* 为代价的——*Multi-LoRA* 倾向于将所有内容判为违规, 导致大量安全内容误报。

2.3 四种方法平均值对比

3 多分类模型全面对比

3.1 整体排名




图 2: 多分类模型 Macro F1 排名

表 12: ID 多分类训练数据标签分布

标签	数量	占比
safe	13,920	30.4%
Harassment	7,020	15.3%
Dangerous _{Content}	6,544	14.3%
Hate _{speech}	5,774	12.6%
ID _{SARA}	5,483	12.0%
Sexually _{Explicit}	4,361	9.5%
ID _{Blasphemy}	1,118	2.4%
Political	967	2.1%
other _{violation}	566	1.2%

表 13: SG 多分类训练数据标签分布

标签	数量	占比
safe	7,822	30.6%
Hate _{speech}	4,500	17.6%
Politically _{sensitiveTopics}	4,500	17.6%
Dangerous _{Content}	1,882	7.4%
Sexually _{ExplicitInformation}	1,843	7.2%
Harassment	1,388	5.4%
SG _{VulgaritySinglish}	1,285	5.0%
SG _{RacialReligiousHarmony}	1,283	5.0%
Cybersecurity _{Malware}	1,040	4.1%

3.2 各标签 F1 热力图

3.3 印尼 (ID) —最优模型详细结果

印尼模型经过 6 个版本迭代, v6 达到最佳效果。

3.4 泰国 (TH) —详细结果

3.5 新加坡 (SG) —详细结果

4 模型演进: 印尼 ID v1 → v6

印尼模型经历了最完整的迭代优化:

1. **v1 (38K, 8-class)**: Full FT (0.692) 和 LoRA (0.690) 基线
2. **v2 (38K, 9-class)**: LSD 蒸馏尝试, F1 0.684, 无明显提升
3. **v3**: 陪审团 relabeling, 修正 ID_SARA/Harassment 混淆
4. **v4**: NIM 生成 2,500 条 ID_SARA 数据, ID_SARA F1: 0.42 → 0.62
5. **v5 (42K)**: 2-seed LoRA LS ensemble + threshold calibration, F1 0.709

表 14: TH 多分类训练数据标签分布

标签	数量	占比
safe	5,998	33.8%
Hate _{speech}	4,500	25.4%
Dangerous _{Content}	1,934	10.9%
Harassment	1,773	10.0%
Sexually _{Explicit} _{Information}	996	5.6%
TH _{Leese} _{Majeste}	969	5.5%
Politically _{sensitive} _{Topics}	901	5.1%
Cybersecurity _{Malware}	680	3.8%

表 15: ZA 多分类训练数据标签分布

标签	数量	占比
safe	7,748	31.9%
ZA _{Xenophobia}	2,827	11.7%
Dangerous _{Content}	2,826	11.6%
ZA _{Severe} _{Racism}	2,763	11.4%
Sexually _{Explicit} _{Information}	1,931	8.0%
Harassment	1,871	7.7%
Hate _{speech}	1,500	6.2%
Cybersecurity _{Malware}	1,398	5.8%
Politically _{sensitive} _{Topics}	1,395	5.8%

6. **v6 (46K)**: 补充 Dangerous_Content (+2,000) + Hate_Speech (+1,500), **F1 0.732**

核心经验: NIM API 数据生成是提升弱势类别的最有效手段。

5 综合仪表盘

5.1 关键发现

1. 全量微调在所有二分类任务中都是最优方法，平均 Macro F1 达到 0.853，比 LoRA 高 0.044，比 Adapter 高 0.084。
2. **Multi-LoRA** 违规召回率最高但安全内容召回率低，倾向于将所有内容判为违规，容易误报。
3. 多分类中泰国 (TH) 表现意外好于印尼 (ID)，可能因为标签更少 (8 vs 9) 且数据标注质量更高。
4. NIM 数据生成是最有效的模型改进手段, ID_SARA (+0.23)、Dangerous (+0.15)、Hate_Speech (+0.09)。
5. **LSD 蒸馏不推荐**，训练慢 5 倍但提升不足 0.01。
6. **Label Smoothing (0.05)** 稳定优于普通 CrossEntropy。
7. **Threshold calibration** 提供 +0.01-0.02 的免费提升。

表 16: SA 多分类训练数据标签分布

标签	数量	占比
none	6,245	30.2%
Hatespeech	5,747	27.8%
SA _{statesecurity} Royalty	2,178	10.5%
Dangerous _C Content	1,237	6.0%
Harassment	1,225	5.9%
Political	1,151	5.6%
other _v iolation	1,031	5.0%
SA _{Religious} violation	1,030	5.0%
SA _L GBTQ _C Content	803	3.9%

表 17: 二分类—全量微调 (Full FT) 完整结果

国家	Acc	Macro F1	Clean P	Clean R	Viol P	Viol R	Viol F1
SG	0.919	0.881	0.950	0.945	0.806	0.821	0.814
SA	0.877	0.874	0.845	0.859	0.900	0.890	0.895
TH	0.875	0.868	0.812	0.862	0.915	0.882	0.898
BR	0.865	0.829	0.939	0.878	0.688	0.825	0.750
MX	0.863	0.850	0.913	0.876	0.777	0.838	0.806
TR	0.862	0.827	0.741	0.757	0.909	0.901	0.905
ID	0.857	0.857	0.865	0.848	0.849	0.866	0.857
ZA	0.849	0.841	0.789	0.824	0.889	0.865	0.877

8. 模型存储效率: LoRA 适配器仅 2.4MB, 比全量微调 (1.1GB) 小 460 倍, 适合多国部署。

6 模型部署

6.1 HuggingFace Hub

所有模型已上传至 HuggingFace Hub: <https://huggingface.co/jianqiang0213>

6.2 使用方法

6.2.1 二分类 Full FT

```
from transformers import AutoModelForSequenceClassification, AutoTokenizer
model = AutoModelForSequenceClassification.from_pretrained(
    "jianqiang0213/mdeberta-v3-SG-binary-fullft"
)
tokenizer = AutoTokenizer.from_pretrained(
    "jianqiang0213/mdeberta-v3-SG-binary-fullft"
)
```

表 18: 二分类—LoRA (PEFT) 完整结果

国家	Acc	Macro F1	Clean P	Clean R	Viol P	Viol R	Viol F1
SG	0.886	0.842	0.951	0.900	0.697	0.832	0.759
SA	0.836	0.829	0.822	0.768	0.844	0.883	0.863
TH	0.840	0.828	0.791	0.774	0.868	0.879	0.873
ID	0.828	0.828	0.862	0.785	0.800	0.872	0.835
BR	0.829	0.795	0.946	0.821	0.608	0.855	0.710
ZA	0.799	0.791	0.710	0.798	0.866	0.800	0.832
TR	0.819	0.784	0.640	0.764	0.905	0.839	0.871
MX	0.785	0.771	0.882	0.778	0.649	0.799	0.716

表 19: 违规召回率 TOP 10 (漏判越少越好)

排名	国家/方法	Viol Recall	Viol F1
1	SA Multi-LoRA	0.983	0.946
2	ZA Multi-LoRA	0.960	0.911
3	ID Multi-LoRA	0.957	0.923
4	BR Multi-LoRA	0.955	0.919
5	TH Multi-LoRA	0.950	0.923
6	MX Multi-LoRA	0.949	0.917
7	TR Full FT	0.901	0.905
8	SA Full FT	0.890	0.895
9	TH Full FT	0.882	0.898
10	ZA Full FT	0.865	0.877

6.2.2 二分类 LoRA (PEFT)

```
from peft import PeftModel
base = AutoModelForSequenceClassification.from_pretrained(
    "microsoft/mdeberta-v3-base", num_labels=2)
model = PeftModel.from_pretrained(
    base, "jianqiang0213/mdeberta-v3-SG-binary-lora")
```

6.2.3 多分类 LoRA

```
base = AutoModelForSequenceClassification.from_pretrained(
    "microsoft/mdeberta-v3-base", num_labels=9)
model = PeftModel.from_pretrained(
    base, "jianqiang0213/mdeberta-v3-ID-v6-multiclass-lora")
```

7 未来工作

1. **补充弱势类别数据:** ZA_Xenophobia (F1=0.21) 和 ZA_Severe_Racism (F1=0.12) 急需 NIM 生成补充 (类似 ID_SARA 策略)
2. **扩展覆盖国家:** 巴西 (BR)、墨西哥 (MX)、土耳其 (TR) 的多分类模型尚未训练

表 20: 二分类—四种方法 8 国平均值

方法	Avg Acc	Avg Macro F1	每国大小	适用场景
Full FT	0.853	0.853	1.1GB	生产环境，精度优先
LoRA	0.814	0.809	3MB	快速部署，接近 FT
Multi-LoRA	0.860	0.796	2MB	多国服务，省空间
Adapter	0.849	0.769	2.5MB	快速原型

表 21: 多分类模型结果汇总

国家	标签数	训练量	Macro F1	训练方法
沙特 (SA)	8	~15K	0.829	全量微调
泰国 (TH)	8	17,751	0.744	LoRA LS + cal
印尼 (ID v6)	9	45,753	0.732	LoRA LS + cal
新加坡 (SG)	9	25,543	0.704	LoRA LS + cal
南非 (ZA)	9	21,329	0.589	LoRA LS + cal

3. **Multi-LoRA 多分类:** 将二分类 Multi-LoRA 架构升级为多分类，实现一个基座服务 8 国 9 类违规检测
4. **模型集成:** 增加 seed 数量到 3 个以上，使用 soft voting 提升稳定性
5. **实际部署测试:** 在真实流量上进行 A/B 测试，验证离线指标与实际效果的一致性
6. **泰国和新加坡的 NIM 生成标签过拟合问题:** Political/Hate_Speech 的接近完美的 F1 表明这些标签存在 NIM 生成数据的特征泄露，需要用真实标注数据验证

附录：模型文件索引

```
Training/model_reports/  
  binary/                # 二分类报告 (32 模型 × 4 方法)  
    fullft/              #   Full FT (8 国)  
    lora/                 #   LoRA PEFT (8 国)  
    multilora/           #   Multi-LoRA (8 国)  
    adapter/             #   Adapter (8 国)  
    shared/              #   架构对比  
    usage_guide.py  
  multiclass/            # 多分类报告 (5 国)  
    id/                  #   ID 6 版本演进  
    sa/                  #   SA 8-class FT  
    sg/                  #   SG 9-class  
    th/                  #   TH 8-class  
    za/                  #   ZA 9-class  
  charts/                # 对比图表 (6 张)
```




图 3: 各标签 $\times$ 各国 F1 热力图 (绿 = 好, 红 = 差)

表 22: ID v6 —各类别完整结果

标签	Precision	Recall	F1	Support
Political	1.000	0.855	0.922	145
ID_Blasphemy	0.974	0.881	0.925	168
safe	0.787	0.793	0.790	2,088
Sexually_Explicit	0.751	0.778	0.764	654
Hate_Speech	0.810	0.599	0.689	866
Dangerous_Content	0.714	0.747	0.730	982
ID_SARA	0.674	0.624	0.648	822
Harassment	0.496	0.618	0.551	1,053
other_violation	0.662	0.506	0.573	85
Overall	—	—	0.732	6,863

—完—

表 23: TH — 各类别完整结果

标签	Precision	Recall	F1
Hate_Speech	0.936	0.982	0.959
Sexually_Explicit	0.934	0.853	0.892
safe	0.863	0.888	0.875
TH_Lese_Majeste	0.792	0.814	0.803
Harassment	0.865	0.722	0.787
Dangerous_Content	0.630	0.793	0.702
Cybersecurity_Malware	0.754	0.422	0.541
Politically_Sensitive	0.465	0.341	0.393
Overall	—	—	0.744

表 24: SG — 各类别完整结果

标签	Precision	Recall	F1
Politically_Sensitive	0.990	0.997	0.993
Hate_Speech	0.953	0.999	0.975
safe	0.865	0.828	0.846
Dangerous_Content	0.772	0.791	0.781
Sexually_Explicit	0.763	0.708	0.734
Harassment	0.759	0.683	0.719
SG_Racial_Religious	0.516	0.492	0.504
SG_Vulgarity_Singlish	0.363	0.513	0.425
Cybersecurity_Malware	0.394	0.333	0.361
Overall	—	—	0.704




图 4: ID 模型 6 版本演进路线

多语言内容审核模型 — 综合对比仪表盘



图 5: 综合仪表盘—6 个维度全面对比

表 25: HF 模型命名规则

类型	Repo ID
二分类 Full FT	mdeberta-v3-{COUNTRY}-binary-fullft
二分类 LoRA	mdeberta-v3-{COUNTRY}-binary-lora
二分类 Multi-LoRA	mdeberta-v3-{COUNTRY}-binary-multilora
多分类 LoRA	mdeberta-v3-{COUNTRY}-multiclass-lora